



TOP 10 worst restaurant nationalities


Add a subtitle

■ avg_score




Made with Graphy





Higher is worse



☰ Borough → Worst Cuisine

Bronx

Pakistani

Brooklyn

Chinese/Cuban

Manhattan

Bangladeshi



Queens

Bangladeshi

Staten Island

Russian

Ranked by number of restaurants





1. Introduction – Contexte & Objectifs

Contexte :

Le Department of Health de New York réalise chaque année plus de 400 000 inspections sanitaires, mais les ressources sont limitées.

Le défi est donc de **savoir où concentrer les efforts** : quels quartiers, quels types de cuisines présentent le plus de risques ?

Mieux cibler les inspections permettrait de **réduire les maladies alimentaires** et **d'améliorer l'efficacité du système**.

Le défi est donc de savoir **où concentrer les efforts d'inspection** :

- Quels **quartiers** présentent le plus de risques sanitaires ?
- Quels **types de cuisines** sont les plus concernés ?
- Quels **facteurs environnementaux**, comme la présence de rongeurs, peuvent expliquer ces écarts ?

Notre équipe, agissant comme un **cabinet de data analysts mandaté par le DOHMH**, a pour mission d'analyser ces données pour comprendre les facteurs expliquant la qualité sanitaire des établissements.

Problématique :

Comment l'analyse des données d'inspection peut-elle permettre d'évaluer la qualité sanitaire des restaurants à New York City et d'identifier des leviers d'action pour réduire les risques d'hygiène alimentaire ?

Impact attendu (business goal) :

Réduire de **15 à 25 %** les maladies alimentaires et augmenter de **30 %** l'efficacité des inspections grâce à une approche ciblée fondée sur les données.



2. Données utilisées

- **inspections_clean** : résultats des inspections sanitaires (score, grade, cuisine, boro...).
- **foodborne_complaints_clean** : plaintes liées à des intoxications alimentaires.
- **Rodent_clean** : données principales issus du service de dératisation

Toutes les données ont été nettoyées sur PostGreSql

Description des principales colonnes des tables

Table **inspections_clean** (issues du DOHMH)

Colonne	Type	Description
camis	TEXT	<i>Identifiant unique du restaurant</i> attribué par le Department of Health. Sert à suivre un établissement dans le temps.
dba	TEXT	<i>Doing Business As</i> – nom commercial du restaurant.
boro	TEXT	Borough où se situe le restaurant (Manhattan, Bronx, Brooklyn, Queens, Staten Island).
building / street / zipcode	TEXT	Adresse complète de l'établissement.

cuisine_description	TEXT	Type de cuisine principale (ex : “Indian”, “Chinese”, “American”).
inspection_date	DATE	Date de l’inspection sanitaire.
score	NUMERIC	Score attribué par l’inspecteur (plus le score est élevé → plus l’hygiène est mauvaise).
grade	TEXT	Note officielle affichée au restaurant (A, B, C).
violation_description	TEXT	Détail de la violation constatée lors de l’inspection.
latitude, longitude	NUMERIC	Coordonnées géographiques pour la cartographie.
nta	TEXT	<i>Neighborhood Tabulation Area</i> — zone géographique fine utilisée pour les analyses locales.

 Table `foodborne_complaints_clean` (issues du 311 NYC Service)

Colonne	Type	Description
complaint_type	TEXT	Type de plainte (ex : “Food Poisoning”, “Restaurant Sanitation”).

borough	TEXT	Borough où la plainte a été déposée.
date_received	DATE	Date de la plainte 311.
descriptor	TEXT	Description détaillée de la plainte (ex : “dirty conditions”, “employee not wearing gloves”).
latitude, longitude	NUMERIC	Localisation de l’incident pour croisement géographique.

Table rodent_clean

Colonne	Type	Description
inspection_type	TEXT	Type d’inspection (“Initial Inspection”, “Follow-Up”, etc.)
result	TEXT	Résultat (“Rat Activity”, “Passed”, “Bait applied”...)
borough	TEXT	Borough concerné
inspection_date	DATE	Date de l’intervention
latitude / longitude	NUMERIC	Coordonnées pour croisement spatial

zip_code	TEXT	Code postal de la zone inspectée
----------	------	----------------------------------

Colonne spécifiques dans les jointures

Colonne	Rôle	Source
avg_score	Moyenne du score d'hygiène par regroupement (cuisine, borough, etc.)	Calculée à partir de inspections_clean
avg_income	Revenu médian moyen des zones où se situent les restaurants du groupe	Calculée à partir de neighborhood_fin_health_clean
restaurants	Nombre de restaurants distincts (COUNT(DISTINCT camis)) pour un type de cuisine	Calculée après jointure

Étape 2 – Nettoyage et préparation des données

Avant toute analyse, les données brutes ont été **nettoyées, typées et harmonisées** directement dans PostgreSQL.

Cette étape est essentielle pour garantir la fiabilité des analyses et la cohérence entre les différents jeux de données.

♦ 2.1 – Table **inspections_raw** → **inspections_clean**

But :

Préparer les données d'inspection issues du **NYC Department of Health and Mental Hygiene (DOHMH)**

pour les rendre exploitables (scores numériques, dates valides, colonnes essentielles conservées).

Nettoyages effectués :

- Suppression des colonnes non pertinentes (**phone**, **location**, etc.)
- Conversion des types :
 - **score** → **NUMERIC**
 - **inspection_date** → **DATE**
- Uniformisation des identifiants de restaurant (**camis**)
- Suppression des doublons sur **camis + inspection_date**
- Harmonisation des noms de boroughs (ex : "StatenIsland" → "Staten Island")

Exemple de commande :

```
CREATE TABLE inspections_clean AS
```

```
SELECT
```

```
    camis::TEXT AS camis,
```

```
    dba::TEXT AS dba,
```

```
    boro::TEXT AS boro,
```

```
    zipcode::TEXT AS zipcode,
```

```
    cuisine_description::TEXT AS cuisine_description,
```

```
    TO_DATE(inspection_date, 'MM/DD/YYYY') AS inspection_date,
```

```
    action::TEXT AS action,
```

```
    violation_description::TEXT AS violation_description,
```

```
critical_flag::TEXT AS critical_flag,  
score::INTEGER AS score,  
grade::TEXT AS grade,  
latitude::DOUBLE PRECISION AS latitude,  
longitude::DOUBLE PRECISION AS longitude  
FROM inspections_raw;
```

♦ 2.2 – Table **foodborne_complaints_raw** → **foodborne_complaints_clean**

But :

Conserver uniquement les plaintes 311 liées à des incidents alimentaires et les rendre géolocalisables.

Nettoyages effectués :

- Sélection des colonnes utiles : **borough, complaint_type, descriptor, latitude, longitude, date_received**

Exemple de création :

```
CREATE TABLE foodborne_complaints_clean AS  
SELECT  
    complaint_number, -- identifiant  
    incident_address_zip::VARCHAR(10) AS zipcode, -- pour la jointure  
avec inspections
```

```

    incident_address_borough::VARCHAR(50) AS boro, -- pour l'analyse
par borough

    complaint_type_311::VARCHAR(100) AS complaint_type,

    descriptor_1_311::TEXT AS description,

    complaint_status::VARCHAR(50) AS status,

    TO_DATE(date_received, 'MM/DD/YYYY') AS date_received, --
conversion en date

    latitude::DOUBLE PRECISION,

    longitude::DOUBLE PRECISION

FROM foodborne_complaints

WHERE incident_address_zip IS NOT NULL

    AND complaint_type_311 IS NOT NULL;

```

Table rodent_raw → rodent_clean

Objectif :

Rendre les données d'inspection des rongeurs exploitables pour analyse par quartier.

Nettoyages :

- Conservation des colonnes essentielles : borough, result, latitude, longitude, inspection_date
- Conversion en types corrects (NUMERIC / TEXT / DATE)
- Suppression des doublons et valeurs NULL
- Uniformisation des noms de boroughs (mêmes conventions que dans inspections_clean)

🧩 2.4 – Harmonisation entre les jeux de données

Les trois tables finales (`inspections_clean`, `foodborne_complaints_clean`, `rodent_clean`) ont été reliées grâce à des variables communes :

- `boro` ↔ `borough`
- `zipcode` ou `neighborhoods` selon la granularité

Des jointures simples (`LEFT JOIN`) ont ensuite permis de croiser les informations d'hygiène, socio-économiques et géographiques.

🔍 3. Analyses effectuées

3.1 — Analyse 1 : Scores moyens par type de cuisine

```
SELECT
    cuisine_description,
    ROUND(AVG(score::NUMERIC), 2) AS avg_score,
    COUNT(DISTINCT camis) AS nb_restaurants
FROM inspections_clean
WHERE score IS NOT NULL
GROUP BY cuisine_description
ORDER BY avg_score DESC;
```

3.2 — Analyse 2 : Évolution des scores dans le temps

```
SELECT
    EXTRACT(YEAR FROM inspection_date::DATE) AS year,
    ROUND(AVG(score::NUMERIC), 2) AS avg_score
FROM inspections_clean
GROUP BY year
```

```
ORDER BY year;
```

3.3 — Analyse 3 : Scores moyens par borough

```
SELECT
    boro,
    ROUND(AVG(score::NUMERIC), 2) AS avg_score
FROM inspections_clean
GROUP BY boro
ORDER BY avg_score DESC;
```

3.4 Corrélation entre plaintes et scores sanitaires

```
SELECT
    i.boro,
    ROUND(AVG(i.score::NUMERIC), 2) AS avg_score,
    COUNT(DISTINCT f.complaint_type) AS nb_complaints
FROM inspections_clean i
LEFT JOIN foodborne_complaints_clean f
    ON i.boro = f.boro
GROUP BY i.boro
ORDER BY nb_complaints DESC;
```

3.5 Densité d'établissements par quartier

```
SELECT
    boro,
    COUNT(DISTINCT camis) AS nb_restaurants,
    ROUND(AVG(score::NUMERIC), 2) AS avg_score
FROM inspections_clean
GROUP BY boro
ORDER BY nb_restaurants DESC;
```

3.6 Taux d'activité de rats par borough

```
SELECT
    borough,
```

```
COUNT(*) AS total_inspections,  
SUM(CASE WHEN LOWER(result) LIKE '%rat%' THEN 1 ELSE 0 END) AS  
rat_inspections,  
ROUND(100.0 * SUM(CASE WHEN LOWER(result) LIKE '%rat%' THEN 1 ELSE  
0 END) / COUNT(*), 2) AS rat_rate  
FROM rodent_clean  
WHERE borough IS NOT NULL  
GROUP BY borough  
ORDER BY rat_rate DESC;
```

4. Conclusions & Interprétation

- Les différences d'hygiène entre cuisines et quartiers ne sont pas aléatoires.
- Les zones où la présence de rongeurs est plus forte affichent des scores sanitaires plus élevés.
- Les plaintes citoyennes corroborent ces observations : les quartiers défavorisés et denses cumulent plus d'incidents.

En résumé :

Les inégalités sanitaires à New York s'expliquent en partie par des conditions environnementales locales — notamment la présence de nuisibles.

5. Impact & Recommandations

En exploitant ces insights :

- Les autorités sanitaires pourraient réduire de **15 à 25 %** les cas de maladies alimentaires.
- L'efficacité du système d'inspection pourrait s'améliorer de **+30 %** en ciblant mieux les zones vulnérables.
- Le modèle pourrait servir de base à un **outil prédictif** de risque par quartier et type de cuisine.

Recommandations Business – DOHMH **(Department of Health & Mental Hygiene)**

1 Cibler les inspections selon le risque

Prioriser les interventions dans :

- les quartiers à forte activité de rongeurs
- les cuisines présentant des antécédents de scores élevés
- les zones avec un grand nombre de plaintes 311

2 Mettre en place une cartographie dynamique du risque sanitaire

Créer une **carte interactive** (alimentée par les données de revenus, inspections et plaintes)
pour visualiser les “**hotspots**” d'hygiène à New York City.

Les inspecteurs pourraient planifier leurs tournées en fonction du **niveau de risque géographique**, et non de manière aléatoire.

3 Alerte prédictive

Mettre en place un système d'alerte lorsque :

- la présence de rats augmente dans un quartier
- ou qu'un type de cuisine présente des anomalies sanitaires répétées.

